

Cross-Architecture 객체 검출기에 대한 전이성 높은 Adversarial Patch 생성

CNN(YOLOv8)과 Transformer(RT-DETR)를 동시에 공격하는 단일 패치

가분반 38팀 20223036 김영재

연구 배경

객체 검출기의 확산

자율주행 · 보안 카메라 · 스마트 팩토리 등 안전에 민감한 영역에 폭넓게 배포된다.

Adversarial Patch 위협

인쇄해 부착 가능한 물리적 공격으로, 사람 검출 자체를 회피시킬 수 있다.

혼합 배포 환경

CNN 계열(YOLO)과 Transformer 계열(RT-DETR)이 현장에서 함께 운용된다.

핵심 전제 — 공격자는 배포된 모델의 백본 아키텍처를 알 수 없다 (black-box).
따라서 한 모델에만 맞춘 패치는 실제 위협이 되기 어렵고, 아키텍처를 가로지르는 전이성이 핵심이다.


문제 정의

단일 모델 패치는 아키텍처를 넘지 못한다


- CNN은 지역적 텍스처(local texture) 중심으로 feature를 학습한다.
- Transformer는 전역적 attention 중심으로 학습한다.

→ 한 모델에서 최적화된 패치는 model-specific local optimum에 갇혀 다른 아키텍처로 전이에 실패한다.

Bayer et al.(2024)은 28개 검출기 분석에서
CNN→Transformer 전이 시 공격 효과가 급감함을 보였다.



RT-DETR 모델로 생성한 패치



YOLO모델로 생성한 패치

단일 모델 패치는 서로 다르고, 자기 아키텍처에서만 통한다.

CNN과 Transformer를 동시에 속이는 단일 패치를 만들 수 있는가?

제안 방법

양상블 손실: $L_{total} = \alpha \cdot L_{YOLO} + \beta \cdot L_{RTDETR}$ 두 검출기의 confidence를 함께 낮추도록 PGD로 패치를 최적화

사람 bbox에
패치 부착



YOLOv8 · RT-DETR
동시 forward



두 검출 손실
결합



PGD로
패치 갱신

추가 제안 - Min-Max 균형 최적화

단순 가중합은 한쪽 아키텍처로 쏠릴 수 있다. 매 스텝 confidence가 더 높은(덜 공격된) 모델을 우선 공격해

$L = \max(L_{YOLO}, L_{RTDETR})$ 형태로 두 아키텍처 사이의 균형을 유도한다.

실험 설정

데이터셋

- COCO val2017 person 서브셋
- 이미지 2,347장

학습 / 평가 모델

- YOLOv8n — CNN (학습)
- RT-DETR-L — Transformer (학습)
- YOLOv10n — unseen (전이성 검증)

비교군

- Baseline A · B (단독)
- 앙상블 (α/β 3:7, 5:5, 7:3)
- Min-Max 균형

학습 설정

- 50 epochs
- PGD 20 step (2/255)
- 패치 = bbox의 50%

실험 결과 1

수치 = mAP drop (전체 2,347장, ↑ 높을수록 공격 성공) · 기준 mAP: YOLOv8 0.527 / RT-DETR 0.417 / YOLOv10 0.493


패치	YOLOv8	RT-DETR	YOLOv10
Baseline A (YOLO)	0.223	0.090	0.107
Baseline B (RT-DETR)	0.108	0.117	0.098
양상블 5:5	0.107	0.089	0.101
양상블 7:3	0.157	0.091	0.097
Weighted (제안)	0.107	0.083	0.101
Min-Max (제안)	0.154	0.081	0.097

핵심 관찰

- 단일 모델은 자기 계열에 강하게 편향
(Baseline A: YOLO 0.223 vs RT-DETR 0.090)
 - 양상블·균형 기법은 두 아키텍처를 함께 공격하지만,
가중합·Min-Max 모두 0.08~0.16 수준에서
비슷하게 머문다.
- 손실을 어떻게 결합하든 cross-architecture
공격에 뚜렷한 우위가 없다. 왜 그럴까?

핵심 분석

학습 곡선: 모델별 confidence(좌) / gradient cosine 유사도(우)



선행 연구와의 차이:

양상블 gradient의 cosine 분석은 AdaEA(ICC 2023)에서 제시됐으나, 이는 이미지 분류·전체 perturbation 영역에서 gradient 충돌(음수)을 다룬다. 본 연구는 이를 객체 검출·패치로 확장했고, CNN·Transformer 검출기 사이에서는 충돌이 아닌 직교(≈ 0)가 나타남을 보인다.

Gradient 직교성 발견

두 모델 gradient의 cosine 유사도가 전 학습 구간에서 ≈ 0 으로 측정됐다.


즉 한 아키텍처를 속이는 방향이 다른 아키텍처에는 거의 무관(직교)하다.

→ 충돌이 아닌 독립이므로, 손실을 어떻게 결합하든(가중합·Min-Max) 결과가 비슷하다. 이것이 앞 표에서 모든 결합 방식이 비슷했던 근본 원인이며, cross-architecture 공격이 본질적으로 어려운 이유다.

해결: Feature-Level 공격

출력 손실 대신 두 모델이 공통으로 의존하는 중간 feature를 직접 교란한다.


Feature-Disrupt: YOLO 0.234 / RT-DETR 0.243 / unseen 0.147 → 성능 우수 + 균형




생성된 패치

사람 눈엔 무의미한 노이즈처럼 보이지만, 검출기의 내부 feature를 교란하도록 최적화됨

(a) YOLO-only



(b) RT-DETR-only



(c) Feature-Disrupt (ours)



결론 · 향후 연구

결론

손실 결합 앙상블은 두 아키텍처의 gradient가 직교($\cos \approx 0$)하여 한계가 있음

중간 feature를 직접 교란하면 두 아키텍처를 동시에 균형 있게 공격할 수 있음 (unseen 모델(YOLOv10)로의 전이도 가장 우수)

직교 gradient임에도 효과가 큰 것은, 공통 표현(feature)을 교란하기 때문

한계

- 절대 mAP drop 폭은 제한적
(패치 크기 · confidence 억제 손실 · epoch 제약)

향후 연구

- 더 다양한 검출기 쌍 확보
- EOT로 물리적 강건성 확보
- 더 다양한 unseen 모델로 일반화 검증